

Informe de resultados de investigación: análisis de contrataciones públicas (2011–2023)

Resumen

Este informe presenta los resultados de una investigación basada en registros de contrataciones desde 2011 hasta 2023. A partir de un análisis exploratorio de datos (EDA) se observó que, para licitación pública nacional, el monto de contrato no sigue una distribución normal; en cambio, contratación directa y concurso de oferta muestran una tendencia más cercana a la normalidad. No obstante, en todas las categorías se identifica una dispersión significativa. En la etapa de modelado, se aplicó KNN para estimar la probabilidad de cancelación en el conjunto “concurso de oferta”, encontrándose una probabilidad global baja de cancelación. Asimismo, se entrenó un modelo de regresión lineal múltiple para predecir el monto de contrato (concurso de oferta, contratos posteriores a 2016) utilizando duración del contrato (días) y número de oferentes; el desempeño obtenido ($R^2=0,12$) sugiere una relación débil entre las variables seleccionadas y el monto. Finalmente, se realizó clustering sobre contratos posteriores a 2017 (set de datos total), identificándose 4 clusters mediante el método del codo.

1. Objetivo y alcance

Objetivo general. Describir patrones y comportamientos del monto de contrato y variables asociadas en las contrataciones públicas del período 2011–2023, y evaluar el potencial predictivo/explicativo de modelos supervisados y no supervisados.

Alcance del análisis. (i) EDA para comparar la distribución del monto de contrato en las categorías: licitación pública nacional, contratación directa y concurso de oferta; (ii) clasificación (KNN) para estimar la probabilidad de cancelación usando el set de datos “concurso de oferta”; (iii) predicción del monto mediante regresión lineal múltiple en “concurso de oferta” para contratos posteriores a 2016; y (iv) clustering en el set de datos total para contratos posteriores a 2017.

2. Datos

El análisis se realizó sobre registros de contrataciones del período 2011–2023. Para mantener la comparabilidad en montos, se trabajó con importes expresados en

guaraníes y, para el foco principal del estudio, se filtró por categorías. Adicionalmente, se utilizaron subconjuntos específicos para tareas de modelado: (a) “concurso de oferta” para clasificación (cancelado/no cancelado) y para regresión (contratos posteriores a 2016); y (b) set de datos total para clustering (contratos posteriores a 2017).

3. Metodología

3.1. Análisis exploratorio de datos (EDA)

Se realizó un EDA orientado a evaluar la distribución del **monto de contrato** por tipo de procedimiento. Se analizaron medidas descriptivas y visualizaciones (p. ej., histogramas y diagramas de caja) para identificar asimetrías, valores extremos y dispersión. Como resultado, se determinó que el monto de contrato en “licitación pública nacional” no presenta comportamiento compatible con normalidad; mientras que “contratación directa” y “concurso de oferta” evidencian una tendencia más cercana a la normalidad. En los tres casos, la variabilidad observada es alta, lo que sugiere heterogeneidad relevante en los montos adjudicados.

3.2. Clasificación: K-Nearest Neighbors (KNN) para cancelación de contratos

Para el proceso de clasificación se utilizó el set de datos “concurso de oferta” con el objetivo de representar matemáticamente la probabilidad de que un contrato resulte **cancelado**. Se aplicó el algoritmo KNN como clasificador, interpretando su salida como una estimación de probabilidad basada en la proporción de vecinos cercanos pertenecientes a la clase “cancelado”. Los resultados indicaron una **muy baja probabilidad** de cancelación en el conjunto analizado, lo que sugiere que la cancelación es un evento poco frecuente (posible desbalance de clases) dentro de esta categoría.

3.3. Predicción del monto: regresión lineal múltiple

Se diseñó un modelo para predecir el **monto de contrato** del set de datos “concurso de oferta” en contratos posteriores a 2016, utilizando **regresión lineal múltiple**. Las variables explicativas seleccionadas fueron: (i) **duración del contrato (días)** y (ii) **número de oferentes**, por ser las que mostraron mayor correlación con el monto en el análisis preliminar. El modelo obtuvo un $R^2=0,12$, lo cual indica que la proporción de variabilidad del monto explicada por estas variables es baja y, por ende, no se evidencia una relación fuerte entre las variables aplicadas y el monto de contrato en este conjunto.

3.4. Agrupamiento (clustering) no supervisado

Para el proceso de clustering se utilizó el set de datos total, restringido a contratos posteriores a 2017. Con el objetivo de identificar una partición razonable del conjunto, se aplicó el **método del codo**, determinándose que **4 clusters** constituyen una opción

adecuada para representar la estructura del set de datos bajo el criterio de reducción marginal de la inercia.

4. Resultados

4.1. Hallazgos del EDA

- **Licitación pública nacional:** el monto de contrato no presenta una distribución normal.
- **Contratación directa y concurso de oferta:** el monto de contrato muestra una tendencia más cercana a la normalidad.
- **Dispersión:** en todas las categorías se observa variabilidad elevada, con indicios de heterogeneidad y posible presencia de valores extremos.

4.2. Resultados de clasificación (KNN): cancelación

- En el set de datos “concurso de oferta”, la cancelación aparece como un evento de baja ocurrencia.
- La estimación de probabilidad de cancelación resultó globalmente baja, consistente con la baja frecuencia observada.
- Este comportamiento sugiere considerar técnicas para datos desbalanceados en análisis futuros (p. ej., métricas específicas, re-muestreo o ajuste de umbrales).

4.3. Resultados de regresión: predicción del monto

- Modelo: regresión lineal múltiple sobre “concurso de oferta” (contratos > 2016), usando duración (días) y número de oferentes.
- Desempeño: $R^2=0,12$, lo que indica baja capacidad explicativa con las variables seleccionadas.
- Interpretación: el monto de contrato probablemente depende de otros factores no incluidos (p. ej., objeto del contrato, entidad convocante, rubro, modalidad de evaluación, presupuesto referencial, etc.).

4.4. Resultados de clustering

- Se aplicó clustering sobre el set de datos total para contratos posteriores a 2017.
- El método del codo sugirió **k=4** como número plausible de clusters.
- Se recomienda caracterizar cada cluster mediante estadísticos por variables clave (monto, duración, oferentes, entidad, rubro) para interpretar los perfiles resultantes.

5. Discusión y limitaciones

Los resultados del EDA muestran que la distribución del monto varía según el tipo de procedimiento, destacándose la no normalidad en licitación pública nacional. La alta dispersión observada en todas las categorías puede afectar tanto la interpretación descriptiva como el desempeño de modelos, en particular aquellos sensibles a valores extremos. En clasificación, la baja probabilidad de cancelación en “concurso de oferta” es consistente con un posible desbalance de clases, lo que requiere precaución al interpretar probabilidades y métricas. En regresión, el R^2 bajo (0,12) sugiere que duración y número de oferentes no capturan adecuadamente los determinantes del monto, por lo que sería necesario incorporar variables adicionales y/o considerar modelos no lineales. En clustering, la identificación de 4 grupos es un primer paso; la utilidad del agrupamiento depende de la interpretación de los perfiles y su estabilidad frente a cambios en variables o escalamiento.

6. Conclusiones y recomendaciones

- El monto de contrato en licitación pública nacional no sigue una distribución normal; en contratación directa y concurso de oferta la distribución es más cercana a normalidad, aunque con alta dispersión en todos los casos.
- En “concurso de oferta”, la cancelación parece ser un fenómeno poco frecuente, por lo que futuros modelos deberían tratar explícitamente el desbalance de clases.
- El modelo de regresión lineal múltiple con duración y número de oferentes mostró baja capacidad explicativa ($R^2=0,12$), sugiriendo que el monto depende de variables adicionales o de relaciones no lineales.
- El análisis de clustering para contratos posteriores a 2017 sugiere 4 grupos; se recomienda describir e interpretar cada cluster para convertir el resultado en evidencia accionable.